

Water Quality and Potability

REDES NEURONALES Y APRENDIZAJE PROFUNDO

TAFFOURAUD GONZÁLEZ-PALACIOS, GUILLERMO
PÉREZ CEMBRANOS, ADRIANA

Índice

1.	Introducción.....	2
2.	Materiales	2
2.1	Descripción del dataset.....	2
2.2	Preprocesamiento de los datos.....	3
2.3	Selección de atributos.....	3
2.4	Visualización de los atributos	4
2.4.1	Histogramas de las variables:	4
2.4.2	Distribución comparativa por Potabilidad:.....	5
2.4.3	Matriz de correlación de variables:	6
2.4.4	Matriz de dispersión	7
2.4.5	Diagramas de cajas y bigotes:	8
3.	Métodos	8
3.1	Preprocesado del Modelo:	8
3.2	Arquitectura del Modelo:.....	9
3.3	Entrenamiento del Modelo:	9
4.	Experimentación.....	10
4.1	Evolución experimentos:	10
5.	Resultados.....	12
6.	Conclusiones.....	14
7.	Referencias	15

1. Introducción

El análisis de la calidad del agua, a lo largo de las últimas décadas, se ha realizado a través de análisis de laboratorio, y estos pueden ser costosos y lentos, sobre todo, cuando se necesita resultados en tiempo real.

Hoy en día, la integración de modelos de Redes Neuronales ha cambiado por completo la forma en que se analizan los datos ambientales. El uso de algoritmos de clasificación permite encontrar patrones que antes no se podían hallar fácilmente, y con esto, es posible predecir con alta exactitud si una muestra de agua es apta para el consumo humano, o no[1].

En este proyecto, se realizará un modelo de clasificación basado en Redes Neuronales para procesar un conjunto de datos sobre la calidad, del agua y predecir la variable “Potability”. Para conseguir la mayor exactitud posible, se hará un preprocesamiento de datos que incluye la limpieza, transformación y selección de atributos usando el método de clasificación ANOVA.

El uso de Redes Neuronales para la clasificación de calidad del agua se justifica debido a la naturaleza compleja y no lineal de los datos químicos, los cuales impiden el uso de métodos estadísticos tradicionales. Las redes neuronales son capaces de encontrar relaciones complejas incluso cuando no hay relaciones lineales fuertes, por ello usaremos una red neuronal que incluyan funciones de activación no lineales como ReLU (Rectified Linear Unit)[2].

A través de este proyecto se busca alcanzar una precisión superior al 99% para demostrar la eficacia de las Redes Neuronales, en diagnósticos, pudiendo minimizar así el error humano en la toma de decisiones para la salud pública. Se espera que estos resultados puedan ser de utilidad en el futuro

2. Materiales

En este apartado se detallan las propiedades del conjunto de datos utilizado, así como las herramientas usadas para el preprocesamiento y análisis de los atributos para su selección.

2.1 Descripción del dataset

El dataset que se trabajará durante todo el proyecto será “water_potability.csv” descargado desde Kaggle[3], el cual contiene 10 atributos distintos y 3277 registros. Cada uno representa una muestra de agua con variables químicas y el objetivo de este entrenamiento será predecir la variable Potability (Se indicará 0 si no es potable y 1 si lo es.)

Las variables independientes incluidas en el dataset son:

- **pH:** nivel de acidez del agua.
- **Hardness:** dureza del agua.
- **Solids:** Total de sólidos disueltos.

- **Chloramines:** cantidad de cloraminas presentes.
- **Sulfate:** concentración de sulfatos.
- **Conductivity:** conductividad eléctrica.
- **Organic_carbon:** cantidad de carbono orgánico.
- **Trihalomethanes:** concentración de trihalometanos.
- **Turbidity:** nivel de turbidez del agua.

2.2 Preprocesamiento de los datos

Para conseguir la exactitud máxima de una red neuronal, es importante hacer un buen preprocesamiento de los datos, esto implica someter al dataset a ciertos procesos para hacer que los valores sean lo mas reales posibles. Estos son los pasos que se han seguido para garantizar el mayor porcentaje de “accuracy”.

- Eliminación de duplicados y de valores nulos: se eliminaron las filas idénticas para evitar sesgos de repetición. Esto se consiguió con la función ‘df.drop_duplicates()’, siendo df el dataframe a modificar. Además, dado que las variables ‘pH’, ‘sulfate’ y ‘trihalomethanes’ contenían valores ausentes, se aplicó un suavizado e imputación mediante ‘KNNImputer con 5 vecinos’[4], lo cual permite rellenar los valores faltantes preservando la integridad de los datos.
- Escalado de datos: para poder colocar los datos en una misma escala, se ha aplicado una normalización con la técnica de ‘MinMaxScaler’, la cual inserta los datos en una escala común (valores entre 0 y 1). ‘MinMaxScaler’ usa la siguiente fórmula para el escalado de datos.[4]

$$X_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Imagen 1. Fórmula de la técnica "MinMaxScaler"

2.3 Selección de atributos

Para la optimizar el rendimiento de la Red Neuronal y evitar un ruido innecesario a la hora de entrenarla, se llevó a cabo una selección de atributos a través de algoritmos de ‘scoring’, evaluando así la importancia de cada atributo frente a la variable objetivo.

Para seleccionar el mejor algoritmo de clasificación, se compararon los algoritmos ANOVA e Información Mutua, los cuales son los mejores para analizar atributos para este tipo de red neuronal. Tras una búsqueda exhaustiva, se encontró un artículo de Roberto Battiti en el que se explica que “el algoritmo de ANOVA es peor para este tipo de Red Neuronal ya que encuentra relaciones lineales entre los atributos, mientras que esta está diseñada para modelar patrones no lineales”[5].




Imagen 2. Comparación de importancia de variables generada por nuestro programa.

Por ello, el criterio de selección final para los atributos consistió en el algoritmo de Información Mutua, el cual determinó que 7 de las 10 variables tenían un peso predictivo considerable. Este proceso garantiza que la red neuronal sea entrenada principalmente con atributos determinantes, descartando aquellos que no aportan valor a la clasificación del agua.

2.4 Visualización de los atributos

2.4.1 Histogramas de las variables:




Imagen 3. Histogramas

Los histogramas muestran la distribución general de cada variable química por separado. Esto permite ver que hay variables como “Hardness”, “pH”, o “Sulfate” que siguen una distribución normal, mientras que otras como “Solids” pueden estar un poco más sesgadas[6].

También podemos ver que el escalado de datos se aplicó correctamente, ya que todos los valores están entre 0 y 1.

2.4.2 Distribución comparativa por Potabilidad:




Imagen 4. Distribución Comparativa por Potabilidad

Observamos si hay algún tipo de solapamiento entre las dos clases. Si no lo hubiera, se podría decir que la variable por sí sola es un buen indicador. Sin embargo, en estas gráficas se ve que las distribuciones se solapan casi por completo, por lo que justifica el uso de una Red Neuronal para la clasificación[6].

2.4.3 Matriz de correlación de variables:




Imagen 5. Matriz de correlación de variables

Este mapa de calor indica la correlación lineal entre las variables con valores que van de -1 a 1. Un valor cercano a 0 indica que no hay correlación lineal entre esos dos químicos[6].

En este caso, la mayoría de las celdas tienen un valor cercano a 0. Esto justifica el uso del algoritmo de selección de Información Mutua, ya que detecta patrones no lineales mientras que ANOVA busca relaciones lineales cuando aquí no las hay.

2.4.4 Matriz de dispersión




Imagen 6. Matriz de dispersión (Scatter plot)

Este grafico sitúa las variables predictoras en gráficos de puntos, coloreando los puntos según su potabilidad[6].

En estos gráficos se puede ver que no existe una frontera de decisión lineal clara para la clasificación de los tipos de agua. Esto refuerza la necesidad de utilizar funciones de activación no lineales (como ReLU) para poder separar las clases.

2.4.5 Diagramas de cajas y bigotes:




Imagen 7. Diagramas de caja

Los diagramas de cajas y bigotes muestran la mediana, el rango intercuartílico y los valores atípicos (outliers). Con esto podemos evaluar la dispersión de los datos y argumentar que, aunque la mediana de potables y no potables sea similar en lagunas variables, la cantidad de valores atípicos es considerable. En cambio, la robustez del modelo de red neuronal es suficiente como para manejar estos valores sin perder mucha precisión.

3. Métodos

3.1 Preprocesado del Modelo:

El conjunto de datos presenta una cantidad significativa de valores ausentes en variables críticas como “Sulfate” y “pH”. Para mitigar esto, se implementó una estrategia de imputación avanzada mediante KNNImputer, la cual estima los valores faltantes basándose en la similitud de las muestras vecinas, preservando mejor las correlaciones químicas que un promedio simple [6]. Posteriormente, se aplicó una normalización mediante MinMaxScaler, escalando todas las variables a un rango entre 0 y 1 [4]. Este paso es fundamental para el algoritmo MLP, ya que evita que variables con magnitudes grandes (como “Solids”) dominen el entrenamiento y distorsionen el cálculo de los pesos, permitiendo una convergencia más rápida.

3.2 Arquitectura del Modelo:

Se diseñó un Perceptrón Multicapa (MLP): "El Perceptrón Multicapa o MLP, se trata de una generalización del perceptrón simple, que consta de más de un nivel de neuronas y capas de neuronas denominadas ocultas, situadas entre la capa de entradas y la de salidas, cuyas funciones de activación no son necesariamente lineales. Este tipo de redes se representan por medio de un dígrafo simple que pasa las entradas de capa en capa hasta llegar a la capa final" [8].




Imagen 8. Diagrama modelo MLP [10]

3.3 Entrenamiento del Modelo:

Para introducir la no linealidad en el modelo se utilizó la función de activación ReLU (Rectified Linear Unit). Esta función es esencial para que la red neuronal pueda aprender y generalizar patrones complejos en los datos de calidad del agua, ya que, sin ella el modelo se comportaría como una transformación lineal básica independientemente de su profundidad. Matemáticamente, ReLU se define como:

$$f(x) = \max(0, x)$$

Imagen 8. Fórmula función de activación ReLU

Lo que implica que cualquier valor de entrada negativo se transforma en 0, mientras que los valores positivos se mantienen inalterados [9]. Esta propiedad no solo aporta eficiencia computacional, sino que también ayuda a mitigar el problema del desvanecimiento del gradiente durante el entrenamiento.

El optimizador Adam se seleccionó por su capacidad de adaptar la tasa de aprendizaje para cada parámetro de forma individual [7]. Este algoritmo calcula estimaciones de los momentos primero y segundo de los gradientes (media y varianza no centrada), lo que permite una convergencia más estable y rápida en comparación con el descenso de gradiente convencional.

Para prevenir el sobreajuste, se integró un mecanismo de Early Stopping con una fracción de validación del 10%. Este mecanismo se describe cómo:

"El Early Stopping es una forma de regularización que consiste en detener el proceso de entrenamiento antes de que el modelo comience a aprender el ruido de los datos. Esto se logra monitoreando el desempeño del modelo en un conjunto de validación y finalizando el entrenamiento en el momento en que dicho desempeño deja de mejorar, evitando así que la red se sobreajuste a los datos de entrenamiento" [10].

Para garantizar que la evaluación del Perceptrón Multicapa sea robusta y no dependa de una partición aleatoria de los datos, se implementó una técnica de Validación Cruzada (K-Fold Cross-Validation). "La validación cruzada K-Fold consiste en dividir el conjunto de datos en K subconjuntos o pliegues, y entrenar el modelo K veces, utilizando cada vez un pliegue diferente como conjunto de validación y los restantes para el entrenamiento. Este enfoque permite que cada observación sea utilizada tanto para entrenamiento como para validación, reduciendo la varianza asociada a la partición de datos" [11].

4. Experimentación

Para la obtención del modelo final, se llevó a cabo un proceso de experimentación iterativo. El objetivo fue identificar la arquitectura y el método de preprocesamiento que mejor logran generalizar la complejidad química del dataset de potabilidad.

4.1 Evolución experimentos:

Fase	Descripción del Experimento	Accuracy	Observaciones Técnicas
Exp. 1	Red básica (16, 8) + Imputación por media.	62.15%	Underfitting: El modelo era demasiado simple para capturar las relaciones del pH y sulfatos.
Exp. 2	Red profunda (256x3) sin regularización.	68.40%	Overfitting: La red memorizó el ruido; hubo mucha diferencia entre entrenamiento y prueba.
Exp. 3	Arquitectura (100, 50) sin MinMaxScaler.	51.10%	Inestabilidad: Las variables con rangos grandes (Solids) desestabilizaron el aprendizaje.
Exp. 4	Configuración (64, 32, 16) + KNNImputer.	71.87%	Mejora: Confirmamos que la calidad de los nulos era tan clave como la red misma.
Final	Pirámide (128, 64, 32) + K-Fold + Adam.	78.91%	Modelo Óptimo: Equilibrio entre capacidad de

			detección y generalización.
--	--	--	-----------------------------

Tabla 1. Evolución de los experimentos (elaboración propia)

Para asegurar la fiabilidad de los resultados, optamos por no utilizar una división convencional de 80-20. Aunque es el método más rápido, consideramos que para este dataset era más adecuado implementar una Validación Cruzada de 10 pliegues (10-Fold Cross-Validation).

Nuestra decisión se basó principalmente en evitar lo que se conoce como "sesgo de partición". En una división simple, existe el riesgo de que la precisión del modelo dependa excesivamente de si las muestras seleccionadas para el test son más o menos "fáciles" de clasificar. Al validar el modelo 10 veces sobre combinaciones distintas de datos, eliminamos ese factor de suerte y obtenemos una métrica mucho más realista.

Además, al enfrentarnos a un conjunto de datos con cierto desbalance, el K-Fold nos ha permitido aprovechar el 100% de los registros para el entrenamiento y la validación en diferentes etapas. Esto nos da la seguridad de que el 78.90% de precisión obtenido no es una anomalía estadística, sino un rendimiento sólido y estable que el modelo es capaz de mantener ante datos que no ha visto previamente.

Finalmente, optamos por una arquitectura de pirámide invertida (128-64-32 neuronas). Diseñamos esta estructura para que la primera capa realice una detección amplia de rasgos químicos, mientras que las capas sucesivas actúan como filtros que condensan la información.

Al integrar esta arquitectura con el optimizador Adam y el mecanismo de Early Stopping, logramos que la red se detuviera en el punto óptimo de aprendizaje, evitando que el modelo perdiera capacidad de generalización al enfrentarse a muestras de agua desconocidas.




Imagen 10. Red neuronal MLP

Capa Oculta 1: 128 neuronas (capa de expansión de características).

Capa Oculta 2: 64 neuronas (capa de refinamiento).

Capa Oculta 3: 32 neuronas (capa de abstracción y compresión).

5. Resultados

Tras aplicar la validación cruzada de 10 pliegues y entrenar el modelo final, hemos obtenido un rendimiento muy satisfactorio. El modelo logró converger en 99 iteraciones, demostrando estabilidad en el aprendizaje.

```

=== EVALUACIÓN GLOBAL (CV) ===
Accuracy Promedio: 78.9092%

Classification Report:

```

	precision	recall	f1-score	support
0	0.81	0.76	0.78	1586
1	0.77	0.82	0.80	1586
accuracy			0.79	3172
macro avg	0.79	0.79	0.79	3172
weighted avg	0.79	0.79	0.79	3172

```

ROC AUC: 0.8365

```

Imagen 11. Resultados Globales

Tras completar las pruebas, los datos arrojan un accuracy del 78.91%, una cifra que consideramos muy sólida teniendo en cuenta la volatilidad de los parámetros químicos del agua.

Al observar el desempeño por categorías, notamos un equilibrio interesante: el modelo muestra una precisión del 81% para el agua no potable (clase 0), lo que garantiza que cuando el sistema emite una alerta, existe una alta seguridad de que el agua realmente representa un riesgo. Por otro lado, para el agua potable (clase 1), logramos un recall del 82%. Este es un punto clave de nuestra investigación, ya que indica que la red es capaz de identificar correctamente la gran mayoría de las fuentes de agua aptas para el consumo, minimizando los falsos negativos.




Imagen 12. Matriz de confusión Global

Como se observa en la Matriz de Confusión Global, el modelo clasificó correctamente a 1200 muestras no potables y 1303 muestras potables.




Imagen 13. Curva ROC

Para medir la calidad de las predicciones, utilizamos la Curva ROC. Nuestro modelo alcanzó un AUC (Área Bajo la Curva) de 0.8365. Este valor indica que la red neuronal tiene un 83.6% de probabilidad de distinguir correctamente entre una muestra potable y una no potable, lo cual es un indicador de robustez muy elevado.

6. Conclusiones

El desarrollo de este proyecto nos ha permitido confirmar que la detección de potabilidad mediante redes neuronales es viable y altamente eficaz si se acompaña de un preprocesamiento riguroso. La arquitectura de pirámide invertida (128-64-32) probó ser la mejor opción, ya que permitió filtrar la información de manera progresiva hasta obtener una clasificación estable.

Como conclusión principal, destacamos que el éxito del modelo no dependió solo de la profundidad de la red, sino de la combinación entre el KNNImputer para tratar los valores faltantes y el optimizador Adam. Lograr que el modelo convergiera en menos de 100 iteraciones con este nivel de precisión nos da la confianza de que estamos ante una herramienta robusta, capaz de generalizar sus predicciones ante datos nuevos y servir como una base tecnológica fiable para el monitoreo de la calidad del agua.

7. Referencias

- [1] H. Lisdiana y K. E. Setiawan, «Water potability classification using machine learning: a case study on handling incomplete data», *Commun Math Biol Neurosci*, vol. 2026, n.º 0, p. Article ID 22, mar. 2026, doi: 10.28919/cmbn/9757.
- [2] Y. Chen, L. Song, Y. Liu, L. Yang, y D. Li, «A Review of the Artificial Neural Network Models for Water Quality Prediction», *Appl. Sci.*, vol. 10, n.º 17, p. 5776, ene. 2020, doi: 10.3390/app10175776.
- [3] «Water Quality and Potability». Accedido: 15 de abril de 2026. [En línea]. Disponible en: <https://www.kaggle.com/datasets/uom190346a/water-quality-and-potability>
- [4] «MinMaxScaler», scikit-learn. Accedido: 15 de abril de 2026. [En línea]. Disponible en: <https://scikit-learn/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html>
- [5] R. Battiti, «Using Mutual Information for Selecting Features in Supervised Neural Net Learning», *Neural Netw. IEEE Trans. On*, vol. 5, pp. 537-550, ago. 1994, doi: 10.1109/72.298224.
- [6] «What is Exploratory Data Analysis? | IBM». Accedido: 23 de abril de 2026. [En línea]. Disponible en: <https://www.ibm.com/think/topics/exploratory-data-analysis>
- [7] GeeksforGeeks, "Adam Optimizer", *Deep Learning Articles*, 2023. [En línea]. Accedido: 15 de abril de 2026. Disponible en: <https://www.geeksforgeeks.org/deep-learning/adam-optimizer/>.
- [8] L. V. Sosa Jerez y L. C. Zamora Alvarado, "Estructura de redes neuronales (MLP) y su aplicación como aproximador universal", Monografía de Trabajo de Grado, Proyecto Curricular de Matemáticas, Universidad Distrital Francisco José de Caldas, Bogotá D.C., 2022. [En línea]. Accedido: 16 de abril de 2026. Disponible en: <https://repository.udistrital.edu.co/server/api/core/bitstreams/3373a7c7-b053-467a-aea5-2914b289c666/content>
- [9] Ithy, "ReLU: La Función de Activación en Redes Neuronales", Ithy Technical Articles, 2023. [En línea]. Accedido: 16 de abril de 2026. Disponible en: <https://ithy.com/article/relu-activation-8fgwap94>.
- [10] Towards Data Science, "Early Stopping: an effective tool to regularize neural nets", Towards Data Science Articles, 2023. [En línea]. Accedido: 16 de abril de 2026. Disponible en: <https://towardsdatascience.com/early-stopping-a-cool-strategy-to-regularize-neural-networks-bfdeca6d722e/>.
- [11] CertiDevs, "Scikit-Learn: Validación Cruzada K-Fold", Tutoriales de Machine Learning, 2023. [En línea]. Accedido: 16 de abril de 2026. Disponible en: <https://certidevs.com/tutorial-scikit-learn-validacion-cruzada>.
- [12] A. Richaud, "Redes Perceptrón Multicapa," Antonio Richaud - Blog, 2021. [En línea]. Accedido: 20 de abril de 2026. Disponible en: <https://antonio-richaud.com/blog/archivo/publicaciones/41-redes-perceptron-multicapa.html>.